

Face Coco - WholeBody folosind ResNet-18

Raport Proiect MLAV

Student: Cândea Sebastian-Constantin
Master TAID, Universitatea Politehnica București

2 decembrie 2025

1 Definirea Problemei

Proiectul își propune dezvoltarea unui sistem de computer vision capabil să localizeze cu precizie puncte cheie (landmarks) specifice feței umane, cu un accent particular pe zona ochilor. Aceasta este o problemă de *regresie*, unde modelul primește ca input o imagine RGB decupată conținând o față și returnează un vector de coordonate (x, y) normalizate.

2 Specificul Bazei de Date

Pentru antrenare și validare s-a utilizat setul de date **COCO-WholeBody** [1], o extensie a celebrului dataset COCO care adaugă adnotări detaliate pentru corp, mâini și față.

2.1 Pre-procesare și Filtrare

Deoarece setul original conține imagini diverse (multe fără fețe vizibile sau la rezoluții mici), am implementat un pipeline de filtrare riguros:

- **Selecție:** S-au extras doar adnotările cu flag-ul `face_valid=True`.
- **Filtru de Vizibilitate:** S-au reținut doar imaginile care au puncte cheie etichetate ($v > 0$).
- **Normalizare:** Imaginile au fost decupate folosind `face_box`, redimensionate la 224×224 pixeli, iar coordonatele punctelor au fost normalizate în intervalul $[0, 1]$ relativ la dimensiunile decupajului.

Setul rezultat a fost împărțit în **75% Antrenare** și **25% Validare** (10k imagini).

3 Arhitectură și Librării

Proiectul a fost implementat în **Python**, utilizând framework-ul **PyTorch** pentru deep learning și **Weights & Biases (WandB)** pentru monitorizarea experimentelor.

3.1 Modelul ResNet-18

Am optat pentru o arhitectură bazată pe **ResNet-18** (Residual Network cu 18 straturi), pre-antrenată pe ImageNet. Această alegere oferă un echilibru optim între capacitatea de extragere a trăsăturilor și viteza de inferență.

Modificările aduse arhitecturii standard:

- Stratul final (*Fully Connected*) a fost înlocuit cu un strat liniar cu 12×2 ieșiri (corespunzător coordonatelor x, y pentru cele 12 puncte de interes).
- Funcția de pierdere (Loss Function) utilizată a fost **MSELoss** (Mean Squared Error), ideală pentru probleme de regresie.

- Optimizatorul utilizat a fost **Adam**, cu un *Learning Rate Scheduler* adaptiv care reduce rata de învățare la stagnarea performanței ("ReduceLROnPlateau").

4 Performanța Atinsă

Antrenamentul a rulat timp de 100 de epoci pe un GPU NVIDIA GTX 1660 Ti.

4.1 Grafice de Performanță




Figura 1: Stânga: Evoluția funcției de pierdere (MSE Loss) pe seturile de train și validare. Dreapta: Evoluția Erorii Medii Absolute (MAE).

4.2 Măsurători Statistice

Tabela 1: Rezultate comparative pentru toate experimentele (Metrici de top).

Experiment	Set Antrenare (Best)			Set Validare (Best)		
	Loss	MAE	Acc (%)	Loss	MAE	Acc (%)
Pre-antrenat (BS=32)	0.000039	0.0049	99.51	0.000969	0.0197	98.03
Pre-antrenat (BS=128)	0.000134	0.0090	99.10	0.001085	0.0207	97.93
Scratch (BS=128)	0.000162	0.0099	99.01	0.001297	0.0225	97.75
Scratch (BS=32, Run 1)*	0.000047	0.0053	99.47	0.000997	0.0204	97.96
Scratch (BS=32, Run 2)	0.000285	0.0128	98.72	0.001368	0.0232	97.69

*Run 1 a prezentat instabilitate în fazele inițiale, dar a converș ulterior la valori bune. Run 2 reprezintă o re-rulare pentru validare.



Figură: Graficul evoluției asociat tabelului de mai sus.

4.3 Comparație cu Rezultate din Literatură (State of the Art)

Pentru validarea externă, am raportat rezultatele noastre la performanțele publicate în articolul original **COCO-WholeBody** [Jin et al., 2020], utilizând datele din Tabelul 2 (Validation Set).

Deoarece literatura utilizează metrica *Average Precision (AP)* pentru detecția tuturor punctelor (inclusiv cele ocluse), iar acest proiect utilizează regresia distanței *MAE* pe puncte vizibile, comparația este calitativă și vizează compromisul dintre complexitate și precizie.

Conform [1], performanța pe subșetul *Face* este următoarea:

- **Modele din Literatura:**

- Modelul consacrat **HRNet-w32** obține un scor $AP_{face} = 49.3$.
- Modelul propus de autori, **ZoomNet**, atinge $AP_{face} = 63.3$.

Aceste scoruri AP (sub 65%) indică faptul că problema generală (detectarea feței în orice condiție, inclusiv blur sau ocluzie totală) rămâne o provocare majoră chiar și pentru arhitecturi masive.

- **Modelul Propus (ResNet-18):** Prin concentrarea strictă pe punctele vizibile ($v=2$) și utilizarea regresiei directe, modelul nostru a atins o eroare **MAE = 0.0196**.

- **Concluzie:** Deși **ZoomNet** [Jin et al.] este superior în generalizare pe tot corpul, acesta este un model complex, *multi-stage*. În contrast, abordarea noastră demonstrează că pentru aplicații specifice (ex. monitorizarea atenției șoferului bazată pe ochi), un model **ResNet-18** (mult mai rapid și ușor) poate atinge o precizie excelentă (eroare $< 2\%$), fiind mult mai potrivit pentru integrarea în sisteme embedded sau real-time.

Bibliografie

- [1] Jin, S., Lum, L., Yang, F., et al. "Whole-Body Human Pose Estimation in the Wild." *European Conference on Computer Vision (ECCV)*, 2020.